



UNIVERSIDAD
DE GRANADA

TRABAJO FIN DE GRADO
INGENIERÍA INFORMÁTICA

Algoritmos meméticos para reducir datos de entrenamiento en modelos de aprendizaje profundo convolucionales

Autor

José Ruiz López (alumno)

Directores

Daniel Molina Cabrera (tutor)



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

Granada, Noviembre de 2024

Algoritmos meméticos para reducir datos de entrenamiento en modelos de aprendizaje profundo convolucionales

José Ruiz López (alumno)

Palabras clave: Algoritmos meméticos, Imágenes, Modelos de Aprendizaje profundo convolucionales

Resumen

Los **modelos de Aprendizaje Profundo** (Deep Learning) han supuesto un verdadero hito en la **Inteligencia Artificial**, ya que son capaces de procesar grandes volúmenes de datos...y, además, reconocer patrones sumamente complejos. Dentro de estos, los **modelos convolucionales** se han destacado como particularmente efectivos a la hora de identificar objetos y características en imágenes —una capacidad esencial para muchas aplicaciones modernas—. Sin embargo, a diferencia de los seres humanos, estos modelos requieren un número extremadamente alto de datos de entrenamiento para cada categoría que deben aprender. Esto implica un proceso de entrenamiento más largo y, muchas veces, la recolección de los datos necesarios puede ser problemática, según el tipo de información que se necesite.

Además de la dificultad en la obtención de datos, la reciente **legislación europea sobre IA** (IA Act) [] establece la necesidad de auditar no solo los modelos, sino también los datos utilizados para entrenarlos, especialmente cuando se trata de aplicaciones de IA que manejan datos sensibles. Estas auditorías, por su propia naturaleza, se volverán más complejas conforme aumente el tamaño del conjunto de entrenamiento. Por lo tanto, se vuelve completamente necesario desarrollar estrategias que permitan **reducir el tamaño de los conjuntos de datos de entrenamiento**...sin comprometer la calidad del modelo.

Ya se ha demostrado que aumentar el número de imágenes de entrenamiento puede, en ciertos casos, mejorar el proceso; sin embargo, esto solo sucede cuando las imágenes adicionales realmente contribuyen al aprendizaje. De hecho, las **técnicas de aumento de datos** (Data Augmentation) permiten reducir la necesidad de muchas imágenes similares, ya que estas pueden generarse de manera automática a partir de las ya existentes...lo que además evita problemas legales asociados a la autoría de los datos.

En este trabajo, proponemos el uso de **algoritmos meméticos** combinados con **métricas de similitud entre imágenes** para establecer un

proceso de reducción del conjunto de **entrenamiento** —lo que se conoce como **selección de instancias**—. La idea es seleccionar un conjunto reducido de imágenes representativas que, junto con las técnicas de aumento de datos, sean suficientes para entrenar modelos convolucionales con una calidad óptima. De este modo, se podría reducir significativamente el tamaño del conjunto de entrenamiento, manteniendo la calidad del aprendizaje y, a su vez, facilitando tanto el proceso de auditoría como la eficiencia computacional del sistema.

Memetic Algorithms for Reducing Training Data in Convolutional Deep Learning Models

José, Ruiz López (student)

Keywords: Memetic Algorithms, Images, Convolutional Deep Learning Models

Abstract

Deep Learning models have marked a true milestone in **Artificial Intelligence**, as they are capable of processing large volumes of data... and, moreover, recognizing highly complex patterns. Among these, **convolutional models** have proven to be particularly effective in identifying objects and characteristics in images — an essential capability for many modern applications. However, unlike humans, these models require an extremely high number of training data for each category they need to learn. This implies a longer training process, and often, the collection of the necessary data can be problematic, depending on the type of information required.

In addition to the difficulty of obtaining data, the recent **European AI legislation** (IA Act) [] establishes the need to audit not only the models but also the data used to train them, especially when dealing with AI applications that handle sensitive data. These audits, by their very nature, will become more complex as the size of the training set increases. Therefore, it becomes completely necessary to develop strategies that allow for **reducing the size of training datasets**... without compromising the quality of the model.

It has already been demonstrated that increasing the number of training images can, in certain cases, improve the process; however, this only happens when the additional images actually contribute to learning. In fact, **Data Augmentation techniques** help reduce the need for many similar images, as these can be automatically generated from existing ones... which also avoids legal issues related to data authorship.

In this work, we propose the use of **memetic algorithms**, combined with **image similarity metrics**, to establish a process of **training dataset reduction** — known as **instance selection**. The idea is to select a reduced set of representative images that, along with data augmentation techniques, are sufficient to train convolutional models with optimal quality.

In this way, the size of the training dataset could be significantly reduced, while maintaining the quality of learning and, at the same time, facilitating both the auditing process and the computational efficiency of the system.

Yo, **José Ruiz López**, alumno de la titulación INGENIERÍA INFORMÁTICA de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI **77964364E**, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: José Ruiz López

Granada a X de mes de 201 .

D. **Daniel Molina Cabrera (tutor**, Profesor del Departamento Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado ***Algoritmos meméticos para reducir datos de entrenamiento en modelos de aprendizaje profundo convolucionales***, ha sido realizado bajo su supervisión por **José Ruiz López (alumno)**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a X de mes de 201 .

Los directores:

Daniel Molina Cabrera (tutor)

Agradecimientos

Poner aquí agradecimientos...

Índice general

1. Introducción	1
1.1. Contexto	1
1.2. Motivación	1
1.3. Objetivos	2
2. Metodología y Presupuesto	5
2.1. Metodología	5
2.1.1. Metodología Ágil	5
2.1.2. Fases iterativas	6
2.1.3. Ciclos de trabajo	6
2.2. Presupuesto	7
2.2.1. Mano de obra	7
2.2.2. Recursos computacionales	7
2.2.3. Software y licencias	8
2.2.4. Otros gastos	8
2.2.5. Presupuesto total	9
2.3. Conclusión	9
3. Fundamentos de Aprendizaje Profundo	11
3.1. Definición de Aprendizaje Profundo	11
3.2. Redes Neuronales Artificiales	12
3.2.1. Componentes de una Red Neuronal	12
3.3. Redes Neuronales Convolucionales	13
3.3.1. Componentes principales de una CNN	14
3.3.2. Funcionamiento General de una CNN	15
3.3.3. Aplicaciones de las CNN	15
3.4. Datasets	16
3.4.1. Rock, Paper, Scissors (Piedra, Papel, Tijera)	16
3.4.2. MNIST (Modified National Institute of Standards and Technology)	16
3.4.3. Comparación con otros datasets	17
4. Repaso Bibliográfico	19

5. Descripción de los Algoritmos	21
5.1. Algoritmo Aleatorio	21
5.1.1. Descripción	21
5.1.2. Aplicación en la reducción de datos	21
5.1.3. Resultados esperados	22
5.2. Algoritmo Búsqueda Local	22
5.2.1. Descripción	22
5.2.2. Aplicación en la reducción de datos	23
5.2.3. Ventajas y limitaciones	23
5.3. Algoritmos Genético	23
5.3.1. Descripción	23
5.3.2. Aplicación en la reducción de datos	24
5.3.3. Ventajas y limitaciones	24
6. Implementación	25
6.1. Descripción del Sistema	25
6.2. Herramientas y Lenguajes de Programación	25
6.3. Proceso de Desarrollo	26
7. Desarrollo Experimental	29
8. Conclusiones	31

Capítulo 1

Introducción

1.1. Contexto

En la actualidad, nos encontramos en una era caracterizada por la generación de datos, que crece a un ritmo sin precedentes. Este fenómeno plantea la necesidad de desarrollar métodos capaces de procesar y analizar grandes volúmenes de información de manera eficiente. Los **modelos de aprendizaje profundo** —especialmente las **redes neuronales convolucionales** (CNNs)— han demostrado ser particularmente efectivos en tareas como la **clasificación de imágenes**, el **reconocimiento de patrones** y otras aplicaciones complejas. Sin embargo, el entrenamiento de estos modelos requiere numerosas cantidades de datos, lo que trae consigo importantes desafíos relacionados con el **tiempo de procesamiento**, el **costo económico** y el **consumo de recursos computacionales**.

A medida que los modelos de inteligencia artificial avanzan hacia configuraciones más complejas y precisas, la necesidad de disponer de datos de entrenamiento adecuados y en gran cantidad se hace cada vez más evidente. No obstante, la recolección, almacenamiento y procesamiento de estos datos representan barreras significativas para muchas organizaciones —especialmente aquellas con recursos limitados—, lo que subraya la importancia de explorar enfoques innovadores que permitan la **optimización y reducción** de los conjuntos de datos necesarios para entrenar estos modelos.

1.2. Motivación

La necesidad de **reducir los conjuntos de datos de entrenamiento** surge de la búsqueda por optimizar la **eficiencia** en el desarrollo de modelos de aprendizaje profundo. Si bien las redes neuronales convolucionales

han alcanzado resultados impresionantes, sus **altos costos computacionales** y la extensa cantidad de datos que requieren suponen limitaciones para muchos entornos. Entrenar estos modelos utilizando solo una parte de los datos —seleccionados de manera óptima— podría reducir considerablemente los recursos necesarios (sin comprometer la precisión de los resultados); ello marcaría un avance significativo para la **inteligencia artificial** y sus aplicaciones en entornos con **restricciones de recursos**.

Es aquí donde los **algoritmos meméticos** entran en juego: estos algoritmos combinan las fortalezas de las **técnicas evolutivas** y los **métodos de búsqueda local**, con el fin de optimizar de manera eficiente los conjuntos de datos. La selección de subconjuntos de datos más representativos permite reducir los tiempos de procesamiento y el consumo de recursos sin afectar el rendimiento de los modelos. Así, los algoritmos meméticos se posicionan como una solución prometedora para hacer que el aprendizaje profundo sea más **accesible y eficiente** —incluso en escenarios donde los recursos son limitados—, lo cual es crucial para democratizar el uso de la inteligencia artificial en una amplia gama de aplicaciones.

Este trabajo de fin de grado busca contribuir a esta dirección, explorando la aplicación de algoritmos meméticos en la reducción de datos. La investigación pretende abrir nuevas vías para el desarrollo de modelos más **eficientes**, accesibles y económicamente viables, lo que favorecerá un futuro en el que la inteligencia artificial sea **inclusiva** y más **sostenible**.

1.3. Objetivos

El objetivo principal de este TFG es investigar la aplicación de **algoritmos meméticos** para la **reducción de conjuntos de datos de entrenamiento** en modelos de **aprendizaje profundo convolucionales**. Este estudio permitirá evaluar el impacto de dichos algoritmos en la **eficiencia computacional** y en el **rendimiento de los modelos**. Para cumplir con este objetivo general, se plantean los siguientes **objetivos específicos**:

- **Desarrollar** e implementar algoritmos meméticos que seleccionen subconjuntos óptimos de datos de entrenamiento, con el fin de reducir el volumen de datos requerido para entrenar modelos convolucionales —sin comprometer la precisión de los resultados—.
- **Evaluar** el impacto de la reducción de datos en el rendimiento de los modelos, comparando aspectos clave como la precisión, eficacia y el

tiempo de entrenamiento —en modelos entrenados con conjuntos de datos completos frente a conjuntos reducidos—.

- **Optimizar la eficiencia** del entrenamiento de redes neuronales convolucionales mediante el uso de algoritmos meméticos, analizando los beneficios en términos de reducción de tiempo y costo computacional.
- **Contribuir al avance** de soluciones innovadoras en el campo del aprendizaje profundo, especialmente en escenarios con limitaciones de datos; facilitando así el acceso a esta tecnología a sectores que, de otro modo, tendrían dificultades para implementarla de manera efectiva.

A través de este estudio, se busca no solo mejorar el rendimiento y la eficiencia de los modelos convolucionales, sino también fomentar el desarrollo de soluciones más **sostenibles y accesibles** en el ámbito de la inteligencia artificial.

Capítulo 2

Metodología y Presupuesto

En este capítulo se describe la metodología utilizada para gestionar el desarrollo del proyecto, así como el presupuesto estimado. Se ha optado por una **metodología ágil**, adaptada a la naturaleza iterativa y flexible del desarrollo de un proyecto de investigación como este. Además, se presenta el presupuesto que refleja los recursos empleados, tanto en tiempo como en infraestructura.

2.1. Metodología

El enfoque elegido para la gestión del proyecto ha sido la **metodología ágil**, que permite gestionar proyectos de forma incremental e iterativa. Dado que el desarrollo de un trabajo de investigación implica constantes ajustes y mejoras en cada etapa, la flexibilidad de la metodología ágil ha sido clave para adaptarse a los nuevos descubrimientos y desafíos a lo largo del proyecto.

Para gestionar el proyecto de manera efectiva, se utilizó **Git** [] para el control de versiones del código y el transpaso fácil de datos entre el servidor y el alumno.

2.1.1. Metodología Ágil

La metodología ágil se caracteriza por su capacidad para organizar el trabajo en ciclos cortos, cada uno con objetivos específicos y entregas incrementales. Para este proyecto, la **planificación**, el **desarrollo**, la **investigación** y el **análisis de resultados** no se realizaron como fases completamente separadas, sino que se intercalaron durante todo el ciclo del proyecto.

2.1.2. Fases iterativas

A diferencia de una planificación tradicional secuencial, en este proyecto se ha trabajado en varias fases de forma simultánea y en ciclos iterativos, con los objetivos y prioridades ajustándose a medida que avanzaba el trabajo.

1. Planificación e investigación continua:

- En lugar de una planificación inicial fija, se realizó una planificación continua. Los objetivos de cada iteración se establecían al inicio de cada ciclo de trabajo, según las necesidades y avances previos.
- La investigación sobre los algoritmos y técnicas de reducción de datos fue un proceso continuo, intercalado con el desarrollo y análisis de los resultados obtenidos en las distintas iteraciones.

2. Desarrollo iterativo de los algoritmos:

- La implementación de los diferentes algoritmos (aleatorio, búsqueda local y genéticos) no fue una única fase, sino que se intercaló con la investigación y análisis. Los algoritmos se desarrollaron en incrementos, permitiendo una mejora continua basada en la retroalimentación y pruebas constantes.
- Los algoritmos se evaluaron y ajustaron constantemente, lo que permitió hacer mejoras tempranas y corregir posibles fallos durante el ciclo de desarrollo.

3. Análisis incremental de resultados:

- El análisis de los resultados se realizó tras cada ciclo de pruebas, lo que permitió evaluar el impacto de los cambios implementados en los algoritmos y ajustar la planificación para las siguientes iteraciones.
- Este enfoque incremental permitió identificar patrones y problemas a medida que avanzaba el proyecto, lo que facilitó la optimización de los algoritmos, planificación de nuevas pruebas y la reducción de datos de manera más eficiente.

2.1.3. Ciclos de trabajo

El trabajo se organizó en ciclos de aproximadamente 2 semanas cada uno, donde se definían metas concretas, como la implementación de un algoritmo o la evaluación de un conjunto de resultados. Al final de cada ciclo, se realizaba una revisión de los avances y se ajustaban los objetivos del siguiente ciclo, además de realizar una reunión con el tutor para orientar las nuevas pruebas y los siguientes avances.

Cada ciclo estaba formado por:

1. **Investigación** inicial y **diseño** preliminar del algoritmo.
2. **Implementación** básica del algoritmo y **evaluación** inicial.
3. **Ajustes** en los parámetros del algoritmo y **pruebas** comparativas.
4. **Optimización** y **análisis** final de resultados.
5. **Documentación** del algoritmo y de los resultados obtenidos.

Cada ciclo permitiría la entrega de un incremento funcional del proyecto, con un enfoque en mantener la flexibilidad para adaptarse a cualquier descubrimiento nuevo.

Pero tras atrasarse el desarrollo del TFG, se tuvo que adaptar el tiempo de cada ciclo para que diese tiempo a realizar todas las pruebas necesarias.

2.2. Presupuesto

El presupuesto estimado incluye tanto el tiempo dedicado al proyecto (mano de obra) como los recursos computacionales y otros gastos relacionados. Aunque muchos recursos utilizados son gratuitos o de bajo coste, se ha realizado una estimación considerando el valor del tiempo invertido y el uso de recursos computacionales.

2.2.1. Mano de obra

El trabajo total estimado es de **400 horas**, repartidas de manera flexible a lo largo de los ciclos. El coste por hora se ha estimado en **20 euros**, lo cual incluye las tareas de investigación, desarrollo de algoritmos, análisis de resultados y documentación.

Fase	Horas dedicadas	Coste por hora (€)	Coste total (€)
Planificación e investigación	60	20	1.200
Desarrollo de algoritmos	180	20	3.600
Análisis de resultados	80	20	1.600
Redacción y documentación	80	20	1.600
Total	400 horas		8.000 €

Tabla 2.1: Coste estimado de la mano de obra.

2.2.2. Recursos computacionales

El proyecto ha requerido el uso de recursos computacionales para entrenar los modelos de aprendizaje profundo, especialmente para evaluar la

eficacia de los algoritmos en la reducción de datos.

El tutor **Daniel Molina Cabrera** me puso en disposición el acceso a un servidor de investigación con disponibilidad de GPU, de manera que no ha supuesto ningún coste. Por ello, para suponer un coste estimado, se ha supuesto lo que nos costaría un servidor de **Google Cloud** [] de **Compute Engine** [] en Bélgica.

Los componentes equivalentes del servidor en Compute Engine serían:

- Un **Intel Xeon E-2226G** equivaldría a un **c2-standard-8**, cuyo coste es de 0.43 EUR/h.
- Un **NVIDIA TITAN Xp** equivaldría a una **NVIDIA K80 1 GPU**, GDDR5 de 12 GB cuyo coste es de 0.42 EUR/h.

De manera que los gastos estimados serían:

Recurso	Horas utilizadas	Coste por hora (€)	Coste total (€)
CPU (c2-standard-8)	210	0.43	90.3
GPU (NVIDIA K80 1 GPU)	210	0.42	88.2
Total	210	0.85	178.5

Tabla 2.2: Coste estimado de los recursos computacionales.

2.2.3. Software y licencias

Para este proyecto, todas las herramientas de desarrollo utilizadas han sido de **código abierto**, por lo que no se han generado costes asociados a licencias de software.

2.2.4. Otros gastos

Se han considerado gastos adicionales, como el uso de **conexión a internet** y el consumo de **electricidad** durante el desarrollo y entrenamiento de los modelos.

Concepto	Coste estimado (€)
Conexión a internet	50
Electricidad	40
Total	90 €

Tabla 2.3: Otros gastos estimados.

2.2.5. Presupuesto total

Sumando los costes de mano de obra, los recursos computacionales y otros gastos, el presupuesto total estimado es el siguiente:

Concepto	Coste (€)
Mano de obra	8.000
Recursos computacionales	178.5
Otros gastos	90
Total	8.268,5 €

Tabla 2.4: Presupuesto total estimado del proyecto.

2.3. Conclusión

La utilización de una **metodología ágil** ha permitido gestionar este proyecto de manera flexible y eficiente, favoreciendo la adaptación continua a medida que surgían nuevos retos y descubrimientos. La intercalación de las fases de planificación, desarrollo, investigación y análisis ha garantizado una entrega incremental y un ajuste continuo del trabajo, asegurando la calidad y la optimización de los resultados.

El presupuesto total estimado, de **8.268,5 euros**, refleja principalmente los costes asociados a la mano de obra y los recursos computacionales necesarios para el desarrollo de los modelos y la ejecución de los experimentos.

Capítulo 3

Fundamentos de Aprendizaje Profundo

3.1. Definición de Aprendizaje Profundo

El **aprendizaje profundo** (Deep Learning) es una subcategoría del aprendizaje automático que se basa en el uso de **redes neuronales artificiales** con muchas capas (de ahí el término "profundo"). Estas redes están diseñadas para imitar el funcionamiento del cerebro humano, lo que les permite aprender representaciones complejas de los datos de manera jerárquica.

La principal diferencia entre el **aprendizaje automático tradicional** y el aprendizaje profundo es la manera en que se manejan las características de los datos:

- En los enfoques tradicionales, el ingeniero o científico de datos debe extraer manualmente las características más importantes para entrenar al modelo (por ejemplo, bordes, formas, texturas en imágenes). En el aprendizaje profundo, las redes neuronales son capaces de **aprender automáticamente las representaciones de los datos** a partir de los datos crudos (por ejemplo, imágenes, texto, sonido).
- Este proceso es denominado **aprendizaje de características** (feature learning), lo que reduce la necesidad de intervención humana.

El aprendizaje profundo ha mostrado un rendimiento sobresaliente en diversas tareas, como el reconocimiento de imágenes, el procesamiento del lenguaje natural, la conducción autónoma y el diagnóstico médico, gracias a su capacidad para **capturar patrones complejos** en grandes volúmenes de datos.

3.2. Redes Neuronales Artificiales

Las **redes neuronales artificiales** (ANN) [?] son el corazón del aprendizaje profundo. Estas redes están compuestas por neuronas artificiales, que son unidades matemáticas inspiradas en las neuronas biológicas. Cada neurona toma varias entradas, las procesa mediante una **función de activación**, y produce una salida. Cuando se combinan muchas de estas neuronas en capas, forman una red neuronal.

3.2.1. Componentes de una Red Neuronal

1. Neuronas o Unidades:




Figura 3.1:

Cada **neurona** realiza una operación simple: recibe varias entradas, las pondera por medio de **pesos** w_i , suma estos valores junto con un **sesgo** b , y aplica una función de activación. La salida de la neurona se expresa como:

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b_z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

Luego, el valor z pasa por una función de activación, que introduce la no linealidad en el sistema, permitiendo que las redes neuronales modelen relaciones complejas.

2. Capas de la Red:

- **Capa de entrada:** Es la primera capa de la red neuronal, que recibe los datos crudos (por ejemplo, píxeles de una imagen).
- **Capas ocultas:** Estas capas intermedias entre la entrada y la salida aprenden representaciones abstractas de los datos. En una red profunda, hay múltiples capas ocultas, lo que permite la **transformación jerárquica** de los datos.




Figura 3.2:

- **Capa de salida:** Produce la predicción final, que puede ser una clase (en problemas de clasificación) o un valor numérico (en problemas de regresión).
3. **Pesos y Bias:** Los **pesos** son parámetros ajustables que determinan la importancia de cada entrada en la neurona. El **bias** es otro parámetro que se suma al valor ponderado para desplazar la activación de la neurona y permitir que el modelo ajuste mejor los datos.
 4. **Funciones de Activación:** Las funciones de activación son fundamentales para que las redes neuronales puedan aprender relaciones no lineales. Entre las más comunes se encuentran:
 - **ReLU (Rectified Linear Unit):** $ReLU(x) = \max(0, x)$, que activa solo valores positivos.
 - **Sigmoide:** Que transforma los valores en un rango entre 0 y 1.
 - **Tanh (Tangente hiperbólica):** Transforma los valores en un rango entre -1 y 1.

El uso de **backpropagation** o retropropagación permite ajustar los pesos y biases durante el entrenamiento mediante un algoritmo de optimización, como el descenso de gradiente. De esta manera, la red aprende minimizando la diferencia entre sus predicciones y las respuestas correctas.

3.3. Redes Neuronales Convolucionales

Las **Redes Neuronales Convolucionales** (Convolutional Neural Networks, CNNs) son una clase de redes neuronales profundas especialmente efectivas para el procesamiento de datos que tienen una estructura de tipo rejilla, como las imágenes. Fueron inspiradas por el sistema visual de los mamíferos, donde diferentes capas de neuronas responden a estímulos visuales de manera jerárquica.

Las CNNs son ampliamente utilizadas en tareas de **visión por computador**, como el reconocimiento de imágenes, la segmentación de objetos y la clasificación de imágenes. Lo que diferencia a las CNNs de las redes neuronales tradicionales es su capacidad para detectar **patrones espaciales** como bordes, texturas, y formas, sin necesidad de un procesamiento manual de las características.

3.3.1. Componentes principales de una CNN




Figura 3.3: En esta imagen extraída de [?] puede observarse de la estructura de una red neuronal convolucional. Junto a sus capas convolucionales.

1. **Capas Convolucionales:** Estas capas aplican **filtros o kernels** sobre las imágenes de entrada para detectar características locales, como bordes, esquinas o texturas. Un filtro convolucional es una pequeña matriz que se mueve a lo largo de la imagen, calculando productos escalares en cada posición para producir un mapa de características.

Las convoluciones son útiles porque explotan la **localidad de las características**, es decir, las relaciones espaciales entre píxeles cercanos. Además, la cantidad de parámetros se reduce drásticamente en comparación con las capas densas, ya que el filtro se comparte a lo largo de la imagen.

2. **Pooling (Submuestreo o Agrupamiento):** Las capas de pooling reducen la dimensionalidad de las características extraídas por las capas convolucionales, lo que hace que las representaciones sean más manejables y robustas frente a pequeños cambios o desplazamientos en la imagen.

El max-pooling es la técnica de pooling más común, donde se toma el valor máximo dentro de una ventana de píxeles, reduciendo el tamaño de la imagen, pero reteniendo las características más importantes.

3. **Capas Densas:** Después de varias capas convolucionales y de pooling, se agregan una o más **capas densas** (fully connected) para realizar la clasificación o predicción final. Estas capas toman todas las características aprendidas en las capas convolucionales y las combinan para generar una decisión final.
4. **Batch Normalization:** Esta técnica se utiliza para **normalizar** las salidas de las capas intermedias de una red neuronal. Batch Normalization ayuda a **acelerar el entrenamiento** y a hacer que la red sea más estable, al reducir el **desplazamiento covariante** (cambios en las distribuciones de las entradas de las capas intermedias a lo largo del entrenamiento). Esto se logra al normalizar las entradas de cada capa convolucional o densa antes de aplicar la activación, ajustando su media y varianza.
5. **Dropout:** El Dropout es una técnica de **regularización** que se utiliza para prevenir el **sobreajuste** (overfitting) durante el entrenamiento de una red neuronal. Durante cada iteración del entrenamiento, Dropout **desactiva aleatoriamente** un porcentaje de las neuronas, lo que obliga a la red a no depender excesivamente de ciertas neuronas y a ser más robusta. Esta técnica mejora la generalización de la red, lo que la hace funcionar mejor en datos no vistos.

3.3.2. Funcionamiento General de una CNN

Al pasar una imagen a través de varias capas convolucionales, la red aprende a identificar características simples como líneas y bordes. Conforme avanza a capas más profundas, las características se vuelven más abstractas, capturando patrones más complejos como formas, texturas y, finalmente, estructuras completas como objetos.

Por ejemplo, en una red entrenada para reconocer caras, las primeras capas pueden detectar bordes o contornos, las capas intermedias pueden aprender a reconocer ojos, nariz o boca, y las últimas capas pueden identificar una cara completa.

3.3.3. Aplicaciones de las CNN

- **Clasificación de imágenes:** Etiquetar imágenes en distintas categorías, como identificar animales o vehículos.
- **Detección de objetos:** Identificar y localizar objetos en imágenes.
- **Reconocimiento facial:** Utilizado en sistemas de seguridad, como el desbloqueo de teléfonos móviles.

Las CNN son fundamentales en muchas aplicaciones modernas debido a su capacidad para procesar y entender datos visuales de manera eficiente y automática.

3.4. Datasets

En el aprendizaje profundo, los datasets son colecciones de datos etiquetados o no etiquetados que se utilizan para entrenar modelos. Estos conjuntos de datos suelen contener ejemplos organizados que representan la entrada para el modelo, y en muchos casos, también las etiquetas correspondientes que indican la salida deseada. Los datasets varían en tamaño, calidad y tipo, dependiendo de la tarea a resolver, como la clasificación de imágenes, el reconocimiento de patrones o la predicción de series temporales.

3.4.1. Rock, Paper, Scissors (Piedra, Papel, Tijera)

Rock, Paper, Scissors [?] fue creado originalmente por Laurence Moroney y se utiliza para clasificar imágenes de las manos representando los gestos de ‘piedra’, ‘papel’ y ‘tijeras’. El conjunto de datos contiene alrededor de 2,500 imágenes distribuidas en tres categorías: piedra, papel y tijeras. Las imágenes están en color y tienen un tamaño de 300x300 píxeles.

En este trabajo, se ha utilizado el dataset de **Rock, Paper, Scissors** para evaluar el rendimiento del modelo en un problema de clasificación de imágenes más variado y natural, que involucra múltiples clases. Además, permite explorar la eficacia de los algoritmos meméticos en un entorno más cercano al reconocimiento de objetos, lo que añade mayor complejidad al problema.

3.4.2. MNIST (Modified National Institute of Standards and Technology)

MNIST [?] es uno de los datasets más utilizados en el campo del aprendizaje automático y el aprendizaje profundo. Contiene 70,000 imágenes de dígitos escritos a mano (60,000 para el conjunto de entrenamiento y 10,000 para el de prueba). Las imágenes son en escala de grises y tienen un tamaño de 28x28 píxeles, con cada píxel representando una intensidad de color entre 0 (negro) y 255 (blanco).

Este dataset se utiliza comúnmente como **benchmark** para evaluar modelos de clasificación de imágenes, particularmente en arquitecturas convolucionales.

La simplicidad de **MNIST** lo hace ideal para probar modelos de redes neuronales convolucionales, ya que ofrece un equilibrio entre un problema fácil de entender, pero con suficiente complejidad para que los modelos más avanzados demuestren mejoras.

3.4.3. Comparación con otros datasets

La selección de estos dos datasets responde a la necesidad de evaluar los algoritmos meméticos en distintos niveles de complejidad. **MNIST**, con imágenes en escala de grises de bajo nivel de complejidad, proporciona una referencia clara y estandarizada para comparar el rendimiento y la reducción de datos. Por otro lado, el dataset de **Rock, Paper, Scissors** introduce más desafíos visuales y complejidades, permitiendo analizar cómo los algoritmos meméticos se comportan en escenarios más complejos que podrían ser representativos de aplicaciones más reales en visión por computadora.

Capítulo 4

Repaso Bibliográfico

Capítulo 5

Descripción de los Algoritmos

En este capítulo se describen los diferentes algoritmos utilizados en el desarrollo de este trabajo. Todos ellos tienen como objetivo principal reducir el tamaño del conjunto de datos de entrenamiento utilizado en los modelos de aprendizaje profundo, con el fin de optimizar el rendimiento y reducir el costo computacional. El enfoque adoptado en este trabajo es la aplicación de algoritmos meméticos, los cuales combinan principios de algoritmos genéticos con estrategias de búsqueda local. A continuación, se detallan los algoritmos principales implementados en este proyecto: el **algoritmo aleatorio**, el **algoritmo de búsqueda local** y el **algoritmo genético**.

5.1. Algoritmo Aleatorio

El **algoritmo aleatorio** sirve como referencia básica para medir la efectividad de los algoritmos más avanzados. Este enfoque selecciona subconjuntos de datos de manera completamente aleatoria, sin aplicar ningún tipo de estrategia de optimización.

5.1.1. Descripción

El algoritmo comienza tomando el conjunto de datos completo y seleccionando una fracción de los ejemplos de entrenamiento de forma aleatoria. Esta selección se realiza sin ningún criterio basado en la relevancia de los datos, lo que implica que el conjunto de entrenamiento resultante puede no ser representativo o puede contener redundancias innecesarias.

5.1.2. Aplicación en la reducción de datos

A pesar de su simplicidad, el **algoritmo aleatorio** puede ser útil como método de comparación. En muchos casos, los algoritmos más complejos

deben demostrar que pueden superar este enfoque básico en términos de precisión y eficiencia. Al seleccionar datos de manera aleatoria, este método a menudo produce conjuntos de entrenamiento subóptimos, lo que resulta en modelos menos precisos o con mayor varianza.

5.1.3. Resultados esperados

Debido a la naturaleza aleatoria del algoritmo, los resultados son altamente variables. Es probable que en muchas ejecuciones el rendimiento del modelo entrenado sea inferior al obtenido con métodos más estructurados. Este algoritmo proporciona una línea base importante para evaluar la efectividad de los algoritmos más avanzados.

5.2. Algoritmo Búsqueda Local

El **algoritmo de búsqueda local** es una técnica más sofisticada que explora el espacio de soluciones de manera más estructurada, buscando mejorar progresivamente una solución inicial.

5.2.1. Descripción

La búsqueda local se basa en la idea de comenzar con una solución inicial (un subconjunto de datos) y realizar pequeños cambios o ‘movimientos’ en esa solución para explorar otras soluciones cercanas. En este contexto, cada solución es un subconjunto de datos. El algoritmo evalúa diferentes subconjuntos de datos probando si estos mejoran el rendimiento del modelo de aprendizaje profundo al entrenarlo con ellos.

El proceso básico de la búsqueda local es el siguiente:

1. Se genera una solución inicial, por ejemplo, seleccionando un subconjunto de datos aleatoriamente.
2. Se realizan cambios locales en la solución, como añadir o eliminar ejemplos del conjunto de datos.
3. Se evalúa la nueva solución según el rendimiento del modelo de aprendizaje profundo.
4. Si la nueva solución es mejor, se reemplaza la solución actual por esta.
5. El proceso se repite hasta que no se observan mejoras significativas o hasta que se alcanza un número
6. predefinido de iteraciones.

5.2.2. Aplicación en la reducción de datos

En el contexto de la reducción de datos, el objetivo de la búsqueda local es identificar un subconjunto más pequeño de ejemplos que sea suficiente para entrenar el modelo con un rendimiento similar al obtenido con el conjunto de datos completo. La búsqueda local explora el espacio de posibles subconjuntos, eliminando ejemplos redundantes o irrelevantes, y conservando solo aquellos que son cruciales para el rendimiento del modelo.

5.2.3. Ventajas y limitaciones

Ventajas: Este enfoque permite una exploración más exhaustiva del espacio de soluciones que un algoritmo aleatorio. Al hacer pequeños ajustes en cada iteración, el algoritmo puede encontrar mejores soluciones de manera eficiente. **Limitaciones:** Sin embargo, la búsqueda local puede quedarse atrapada en **óptimos locales**, es decir, soluciones que parecen buenas en comparación con las cercanas, pero que no son globalmente óptimas.

5.3. Algoritmos Genético

Los **algoritmos genéticos** son algoritmos de búsqueda inspirados en los principios de la evolución natural. En este trabajo, se aplican con el objetivo de encontrar subconjuntos óptimos de datos de entrenamiento, reduciendo el tamaño del conjunto mientras se mantiene o mejora el rendimiento del modelo de aprendizaje profundo.

5.3.1. Descripción

El funcionamiento de los algoritmos genéticos se basa en los conceptos de **selección natural**, **cruzamiento** y **mutación**. El proceso se puede resumir en los siguientes pasos:

1. **Inicialización:** Se genera una población inicial de posibles soluciones, cada una de ellas representando un subconjunto del conjunto de datos.
2. **Evaluación:** Cada subconjunto de datos (o 'individuo') es evaluado entrenando el modelo con ese subconjunto y midiendo su rendimiento.
3. **Selección:** Se seleccionan los mejores individuos de la población basándose en su rendimiento. Los mejores individuos tienen más probabilidades de ser seleccionados para la siguiente generación.
4. **Cruzamiento:** Se combinan pares de individuos seleccionados para crear nuevos subconjuntos. Esto se realiza intercambiando ejemplos entre los subconjuntos.

5. **Mutación:** Con una pequeña probabilidad, se realizan cambios aleatorios en algunos individuos, como añadir o eliminar ejemplos del subconjunto.
6. **Iteración:** El proceso de evaluación, selección, cruzamiento y mutación se repite durante varias generaciones, con la esperanza de que cada generación produzca soluciones mejores que la anterior.

5.3.2. Aplicación en la reducción de datos

Los **algoritmos genéticos** son especialmente adecuados para la reducción de datos porque permiten explorar un espacio de soluciones muy amplio de manera eficiente. La combinación de individuos y la introducción de mutaciones aleatorias permiten al algoritmo escapar de los óptimos locales, un problema común en la búsqueda local.

El uso de algoritmos genéticos para reducir datos en este contexto implica encontrar subconjuntos de entrenamiento que proporcionen un buen equilibrio entre tamaño y rendimiento. Esto se logra al evaluar diferentes subconjuntos y mejorar las soluciones generación tras generación.

5.3.3. Ventajas y limitaciones

Ventajas: Los algoritmos genéticos son efectivos para explorar grandes espacios de soluciones y tienen una gran capacidad para evitar quedar atrapados en óptimos locales. Son especialmente útiles en problemas donde la solución óptima no es evidente desde el principio. **Limitaciones:** Estos algoritmos pueden ser costosos computacionalmente, ya que requieren evaluar muchas soluciones a lo largo de múltiples generaciones. **Además**, su convergencia a veces puede ser lenta, dependiendo del tamaño del espacio de búsqueda y de los parámetros del algoritmo (tamaño de la población, tasa de mutación, etc.).

Capítulo 6

Implementación

En este capítulo se detallan la arquitectura del sistema que se ha implementado, como la tecnología usada, diseños, etc.

6.1. Descripción del Sistema

La estructura del proyecto es la siguiente:

- `data` – Almacena los dataset utilizados por el proyecto.
- `docs` – Documentación del proyecto en latex.
- `img` – Imágenes generadas en el proyecto.
- `LICENSE` – Términos de distribución del proyecto.
- `README.md` – Descripción general.
- `requirements.txt` – Dependencias del proyecto.
- `results` – Resultados generados por el proyecto (fitness, tiempos, etc.).
- `scripts` – Scripts y programas secundarios para ejecutarse en el servidor GPU.
- `src` – Código fuente del proyecto.
- `utils` – Módulos y scripts de utilidad.

6.2. Herramientas y Lenguajes de Programación

El desarrollo del proyecto se ha llevado a cabo utilizando **Python 3.10** [] como lenguaje principal, debido a su versatilidad y amplia adopción en el

campo del **aprendizaje profundo** y la **manipulación de datos**. Python es conocido por su facilidad de uso, extensibilidad y la gran cantidad de bibliotecas disponibles para el procesamiento de datos y la implementación de modelos de **machine learning**.

Las principales bibliotecas empleadas durante el desarrollo son las siguientes:

- **PyTorch 2.3.1** []: Biblioteca usada para implementar redes neuronales y modelos de aprendizaje profundo, con flexibilidad para experimentar y aprovechar GPU.
- **Scikit-learn 1.5.2** []: Librería para el procesamiento de datos y modelos de machine learning, que incluye herramientas para selección de características y validación cruzada.
- **Numpy 2.0.0** []: Herramienta para realizar operaciones matemáticas y de álgebra lineal, esencial para manejar grandes conjuntos de datos.
- **Polars 1.9.0** []: Alternativa más eficiente a Pandas, utilizada para gestionar grandes volúmenes de datos y mejorar el procesamiento de DataFrames.

Cada una de estas herramientas fue seleccionada por su robustez y su idoneidad para cumplir con los requisitos específicos del proyecto, facilitando tanto la implementación de los algoritmos meméticos como la reducción y el análisis de los datos utilizados en los modelos de aprendizaje profundo.

6.3. Proceso de Desarrollo

El desarrollo de este Trabajo de Fin de Grado (TFG) se inició con una cuidadosa **planificación inicial**. Se definieron **objetivos claros** y un **plan temporal** que guiaría cada una de las fases del proyecto. El primer paso consistió en llevar a cabo una **investigación preliminar** para comprender el **estado del arte** en cuanto al uso de algoritmos meméticos en el ámbito del **aprendizaje profundo**. Esta investigación incluyó la revisión de trabajos previos relevantes, así como la identificación de las **herramientas y tecnologías** más adecuadas para el desarrollo del proyecto.

Con una base teórica sólida y una planificación definida, se procedió a la **fase de desarrollo**. Esta etapa comenzó con la implementación de un **prototipo inicial**, que permitió realizar pruebas preliminares y sentar las

bases del código principal. A medida que se implementaba esta primera versión, se llevó a cabo una **experimentación iterativa**, un proceso en el que se fueron incorporando **nuevos experimentos** y realizando **ajustes continuos** a partir de los resultados obtenidos. Este enfoque de **desarrollo incremental** permitió refinar el rendimiento de los algoritmos meméticos y mejorar la eficiencia de los modelos.

Finalmente, el proceso culminó con la **documentación exhaustiva** de todos los pasos realizados, así como la **preparación de la presentación** y la **defensa** del proyecto final. La documentación incluyó tanto el **análisis de los resultados experimentales** como una reflexión crítica sobre los logros y las limitaciones del TFG, asegurando que todo el proceso fuera presentado de manera clara y coherente.

Capítulo 7

Desarrollo Experimental

Tras la explicación del contenido necesario para el entendimiento y desarrollo del TFG en los anteriores capítulos, en este capítulo se precedera a explicar las pruebas y posteriores mejoras que se han realizado y los posteriores resultados obtenidos.

Las pruebas iniciales que se plantearon fueron tomar un dataset simple para realizar las primeras pruebas, y ya cuando funcionase correctamente, probar con otro dataset más complejo o realista. Para ello se decidió usar el dataset de **RPS**.

Para obtener unos primeros resultados con este dataset, se planteó usar el modelo de **Resnet50**. Se hicieron unas pruebas con distintos porcentajes para ver distintos resultados posibles.

Algoritmo	Porcentaje Inicial	Duracion	Accuracy (Avg)	Precision (Avg)	Recall (Avg)	F1-score (Avg)	Evaluaciones Realizadas
aleatorio	10	00:45:08	76,55 %	81,80 %	76,55 %	76,25 %	100
aleatorio	20	01:10:27	81,77 %	84,70 %	81,77 %	81,59 %	100
aleatorio	50	02:24:49	87,14 %	88,09 %	87,14 %	86,97 %	100
aleatorio	100	00:02:42	87,90 %	88,96 %	87,90 %	87,81 %	1

Tabla 7.1: Resultados de la generación inicial con **Resnet50**

Fijandonos en la tabla 7.1, las duraciones que se indican son lo que tarda en ejecutarse todas las evaluaciones que se indican. Vemos que son tiempos muy grandes, por ello se decidió probar el algoritmo **MobileNet** para agilizar el proceso.

Algoritmo	Porcentaje Inicial	Duracion	Accuracy (Avg)	Precision (Avg)	Recall (Avg)	F1-score (Avg)	Evaluaciones Realizadas
aleatorio	10	00:29:29	72,31 %	76,40 %	72,31 %	69,62 %	100
aleatorio	20	00:50:36	76,48 %	78,82 %	76,48 %	75,58 %	100
aleatorio	50	01:54:09	75,56 %	79,72 %	75,56 %	74,67 %	100
aleatorio	100	00:02:12	76,08 %	79,97 %	76,08 %	75,61 %	1

Tabla 7.2: Resultados de la generación inicial con **MobileNet**

Capítulo 8

Conclusiones

